UNIVERSIDAD TECNOLÓGICA DEL PERÚ (UTP)
FACULTAD DE INGENIERÍA

CURSO: INNOVACIÓN Y TRANSFORMACIÓN DIGITAL (100000TD09)
PERÍODO ACADÉMICO 2026-2

AVANCE DE PROYECTO FINAL 3 (APF3)
SOLUCIÓN DE MACHINE LEARNING PARA LA MIPYME:
SISTEMA DE INVENTARIO INTELIGENTE Y PREDICCIÓN DE DEMANDA DIARIA POR SKU EN TIENDAS 3A
(SEDE AV. TANTAMAYO 1032, SAN MARTÍN DE PORRES)

Atributo del Proyecto	Detalle Oficial Verificable
Empresa / MiPYME en Estudio	Tiendas 3A — Sucursal Av. Tantamayo 1032, SMP (AJILES PERU S.A.C., RUC 20612232203)
Docente del Curso	Mg. Richard Enrique Caman Sanchez
Integrantes del Equipo (4)	1. Moran, Orestes 2. Campos, Grace 3. Minaya, Julio 4. Damian Quintana, Jardiel Jesus
Modelo Seleccionado (Unidad 3)	Gradient Boosting Regressor (scikit-learn 1.4+) — R^2 = 0.923 | MAPE = 15.63 % | RMSE = 4.48
Repositorio GitHub Oficial	https://github.com/julio060606/InnovacionAPF3
Repositorio Espejo de Respaldo	https://github.com/JesusDamian899/InnovacionAPF3
Notebook Ejecutado (.ipynb)	backend/APF3_TD_Grupo_ML_Innovacion.ipynb (con salidas y gráficos incrustados)
Persistencia Cloud y API	Supabase PostgreSQL (2,970 registros) + Microservicio Flask REST API (Render / Vercel)

Lima, Perú — 2026

1. Resumen Ejecutivo y Definición del Problema de Machine Learning (Paso 1)

1.1. Recapitulación de APF1 y APF2: Continuidad y Trazabilidad

El presente entregable mantiene estricta continuidad metodológica y técnica con el diagnóstico situacional (APF1, Semana 5) y el Producto Mínimo Viable desplegado en la nube (APF2, Semana 10), ratificando el mismo equipo de cuatro integrantes, la misma empresa en estudio y el mismo problema de ingeniería e indicador:

- **MiPYME y Contexto Operativo:** Sucursal Av. Tantamayo 1032 (San Martín de Porres) de Tiendas 3A (AJILES PERU S.A.C., RUC 20612232203), tienda de proximidad bajo formato hard discount que comercializa un catálogo concentrado de 33 SKUs esenciales distribuidos en 7 categorías con exhibición directa en cajas (SRP) y operación ágil de 3 a 4 colaboradores por turno.
- **Problema de Ingeniería Diagnosticado (APF1):** Alta incidencia de quiebres de stock en góndola (On-Shelf Availability) durante las horas punta vespertinas (17:00–21:00 h) y los fines de semana, originada por la estimación manual e intuitiva de pedidos y el desfase entre el inventario de trastienda y el piso de venta.
- **Indicador Base y Brecha Principal:** En la línea base levantada en APF1, la tienda registraba una Tasa de Quiebre en Góndola del 14.2 % en productos Clase A y un Error Porcentual Absoluto Medio (MAPE) de pronóstico empírico del 28.5 %, ocasionando ventas perdidas estimadas en S/ 114.00 diarios (S/ 3,420.00 al mes) y sobrecompras reactivas que elevaban la merma en perecibles.
- **Tecnología Habilitadora, Metodología y Estado del MVP (APF2 -> APF3):** Aplicando Design Thinking y Scrum, en APF2 se construyó y desplegó en Vercel una aplicación web progresiva (React 18 + TypeScript + Vite) con semáforo de góndola, kardex transaccional y alertas logísticas (https://github.com/julio060606/InnovacionAPF3). En este APF3, el MVP evoluciona conectándose a una base de datos relacional en Supabase PostgreSQL y a un microservicio Python/Flask en Render que expone un modelo supervisado de Machine Learning entrenado con scikit-learn y serializado en modelo_demanda_3a.joblib.

1.2. Tipificación del Problema de Machine Learning

El problema se tipifica como Aprendizaje Supervisado de Regresión de valor continuo sobre series temporales multivariadas con variables exógenas (primera fila de la Guía de Selección de Modelos de la Unidad 3, Semanas 13 y 14 del sílabo UTP). Justificación con APF1: Para eliminar los quiebres de góndola sin saturar el almacén de trastienda, el negocio no solo necesita saber si habrá riesgo, sino cuantificar exactamente cuántas unidades o kilogramos se venderán cada día ($\hat{y} \in R+$). Esa cantidad continua alimenta la ecuación logística del Stock de Seguridad (SS) y del Punto de Reorden (ROP) para calcular el número exacto de bultos cerrados a pedir al Centro de Distribución.

1.3. Variable Objetivo, Unidad de Observación y Decisión Habilitada en el MVP

- **Variable Objetivo (Target, y):** unidades_vendidas (float), que mide la demanda diaria total de un SKU expresada en unidades discretas ('un') o kilogramos ('kg' en frutas y verduras).
- **Unidad de Observación:** Cada fila del dataset representa 1 producto específico (sku / producto_id) en 1 fecha calendario cerrada (fecha) en la sede Av. Tantamayo 1032 (1 fila = 1 SKU-día).
- **Decisión de Negocio y Flujo del MVP:** Automatiza el cálculo preventivo de órdenes de compra a bulto cerrado cuando el Stock Actual <= ROP. Se integra directamente en la pantalla del Módulo Predictivo (/prediccion, archivo PredictionsPage.tsx) y en el modal interactivo 'Inferencia ML en vivo' (MLInferenceDialog.tsx), que consume el endpoint POST /api/predict para mostrar la demanda diaria predicha, SS, ROP, nivel de riesgo y bultos sugeridos.

1.4. Métrica de Éxito de Negocio y Costo Asimétrico de los Errores

- **Métrica de Negocio Observable:** Reducir el error de pronóstico de demanda desde el MAPE base de 28.5 % (cálculo empírico actual en tienda) a un MAPE <= 16.0 % en el conjunto de prueba intacto, reduciendo los quiebres de góndola en al menos 60 % (de 14.2 % a < 5.5 %) y recuperando S/ 68.40 diarios (S/ 2,052.00 mensuales) en ventas.
- **Costo Asimétrico de los Errores (Subestimar vs. Sobrestimar):** En Tiendas 3A, subestimar la demanda ($\hat{y} < y$, equivalente funcional al Falso Negativo de alerta de reposición) tiene un costo crítico y muy superior: provoca góndolas vacías en hora

punta, pérdida directa de margen y fuga del cliente hacia bodegas vecinas. En cambio, sobrestimar la demanda (ŷ > y, equivalente al Falso Positivo) tiene un costo moderado (inmovilización temporal en trastienda y riesgo de merma acotado solo a frutas y panadería). Por ello, se selecciona el modelo mediante RMSE y MAPE, y se protege el pronóstico con un Stock de Seguridad al 95 % de nivel de servicio (z = 1.645).

FRASE REGLAMENTARIA DEL PROBLEMA DE MACHINE LEARNING (CONSIGNA SECCIÓN 3):
"Para el administrador de tienda y el encargado de reposición de Tiendas 3A (Sede Av. Tantamayo 1032), el modelo predecirá la demanda diaria en unidades o kilogramos por cada SKU (unidades_vendidas) con el propósito de anticipar los quiebres de stock en góndola y determinar automáticamente el Punto de Reorden (ROP) y la cantidad óptima de bultos a solicitar al Centro de Distribución, medido mediante un MAPE <= 16.0 % y RMSE <= 5.0 unidades en el conjunto de prueba que permitan reducir los quiebres de stock en al menos 60 % (recuperando S/ 2,052.00 mensuales en ventas no perdidas)."

2. Dataset, Coherencia de Datos y Preprocesamiento (Paso 2)

2.1. Origen, Volumen, Simulación Calibrada y Trazabilidad con APF2 (Sección 4.1)

El dataset oficial (backend/data/dataset_ventas_3a.csv y tabla historial_ventas en Supabase PostgreSQL) consta de 2,970 registros diarios (33 SKUs × 90 días calendario continuos, del 2026-08-11 al 2026-11-08), superando ampliamente el mínimo orientativo de 200 filas. En cumplimiento estricto de la sección 4.1 de la consigna, el 100 % de los registros posee rotulada la columna origen = 'simulado'. El procedimiento de generación (migrate_and_seed.py, con semilla fija random.seed(42)) modela la demanda diaria D(i,t) = round(max(0, B_i * W_i(dia) * T_i(t) * Q(t) * N(1.0, 0.15))), calibrando los parámetros con tres fuentes verificables de APF1/APF2: (1) los precios reales en soles y empaques observados en la tienda de Av. Tantamayo, (2) la curva de tráfico semanal del formato hard discount (incremento de viernes a domingo), y (3) el calendario de pagos quincenales en Perú (factor 1.15x los días 1, 15, 16, 30 y 31).

Tabla 1. Matriz de Trazabilidad entre el Contrato de Datos Preliminar (APF2) y el Dataset de ML (APF3)

Elemento / Campo	Contrato de Datos (APF2)	Dataset APF3 (dataset_ventas_3a.csv)	Volumen Esperado vs. Obtenido	Justificación e Impacto en Trazabilidad
Variable Objetivo (Target)	Demanda diaria por SKU (units)	unidades_vendidas (float: 2.0 a 103.0)	Esperado: >= 990 filas (30d) Obtenido: 2,970 filas (90d)	Se conserva intacto el target; se triplicó la historia a 90 días para capturar 6 quincenas y 13 ciclos semanales.
Identificadores de Catálogo	id, sku, name, categoryId	producto_id, sku, producto_nombre, categoria_id, categoria_nombre	33 SKUs en 7 categorías (100 % idéntico)	Trazabilidad exacta 1:1 con src/data/catalog.ts del MVP y la tabla productos en Supabase.
Variables Económicas	price, cost, unit ('un'|'kg')	precio, costo, unidad, ingresos_soles	2,970 registros completos sin nulos	Se agregó ingresos_soles (unidades * precio) para verificación contable y cálculo de impacto económico.
Variables de Calendario	Fecha de operación (date)	fecha, dia_semana, es_fin_de_semana, es_quincena	90 días continuos (2026-08-11 a 2026-11-08)	Permite que los modelos capturen explícitamente el efecto fin de semana y pagos de quincena.
Variables Derivadas (Lags)	Promedio móvil local 7d	lag_1d, lag_7d, media_movil_7d, std_movil_7d	2,739 filas útiles tras ventana de 7 días	Generadas con .shift(1) por SKU para dotar de memoria autorregresiva sin fuga de información.
Rotulado Ético (Sec. 4.1)	No incluido en APF2	origen ('simulado' | 'real')	2,970 filas con origen = 'simulado'	Requisito obligatorio de transparencia de datos de la

				consigna APF3 y Ley N.° 31814.

Tabla 2. Diccionario de Datos del Dataset y Variables de Modelado (Unidad de observación: 1 SKU por día calendario)

N.°	Variable	Rol en ML	Tipo	Unidad	Descripción Técnica y de Negocio	Rango / Valores Válidos Verificados
1	fecha	Índice Temporal	date	YYYY-MM-DD	Fecha de cierre diario de caja en sede Tantamayo.	2026-08-11 a 2026-11-08 (90 días)
2	producto_id	Identificador	string	ID	Clave primaria del producto en el MVP y Supabase.	33 IDs (ej. fv-mandarina, lac-leche)
3	sku	Identificador	string	Código	Código estándar de inventario Tiendas 3A.	3A-FV-001 a 3A-PAN-033 (33 únicos)
4	producto_nombre	Descriptivo	string	Texto	Nombre comercial del producto en góndola.	33 nombres comerciales reales
5	categoria_id	Predictor (X)	categ.	Código	Familia logística del artículo (7 categorías).	{fv, lac, aba, beb, lim, cui, pan}
6	precio	Predictor (X)	float	Soles (S/)	Precio unitario de venta al público en tienda.	S/ 1.50 a S/ 18.90 (media S/ 6.45)
7	costo	Predictor (X)	float	Soles (S/)	Costo unitario de reposición desde el CD.	S/ 0.90 a S/ 14.20 (media S/ 4.68)
8	unidad	Metadato	string	Unidad	Unidad de medida comercial del SKU.	{'un', 'kg'} (homogéneo por SKU)
9	unidades_vendidas	TARGET (y)	float	un o kg	Demanda diaria total registrada por SKU.	2.0 a 103.0 (media 17.72, std 13.75)
10	ingresos_soles	Auditoría	float	Soles (S/)	Facturación bruta diaria (unidades * precio).	S/ 4.50 a S/ 535.50 (media S/ 97.69)
11	dia_semana	Predictor (X)	int	0 a 6	Día de la semana (0=Lunes ... 6=Domingo).	{0, 1, 2, 3, 4, 5, 6}
12	es_fin_de_semana	Predictor (X)	bool/int	Binario	Indicador de viernes (4), sábado (5) o domingo (6).	False (0) o True (1)
13	es_quincena	Predictor (X)	bool/int	Binario	Indicador de pago quincenal (días 1, 15, 16, 30, 31).	False (0) o True (1)
14	lag_1d	Derivada (X)	float	un o kg	Demanda del mismo SKU en el día anterior (t-1).	2.0 a 103.0
15	lag_7d	Derivada (X)	float	un o kg	Demanda del mismo SKU hace exactamente 7 días (t-7).	2.0 a 103.0
16	media_movil_7d	Derivada (X)	float	un o kg	Promedio móvil de los 7 días previos cerrados (shift(1)).	2.29 a 68.57
17	std_movil_7d	Derivada (X)	float	un o kg	Desviación estándar móvil de los 7 días previos cerrados.	0.00 a 24.18
18	origen	Metadato Ético	string	Etiqueta	Rotulado obligatorio del registro (Sección 4.1).	'simulado' (2,970 filas = 100 %)

2.2. Ficha de Coherencia de los Datos (Los 7 Criterios de la Sección 4.2)

La función auditar_coherencia_y_limpieza() en backend/train_model.py y la Celda 2 del notebook ejecutan de forma automatizada las reglas de validación sobre los 2,970 registros, cuyos resultados se sintetizan en la Ficha de Coherencia (Tabla 3):

Tabla 3. Ficha de Coherencia de Datos (Verificación de los 7 Criterios Obligatorios de la Sección 4.2)

Criterio (Sección 4.2)	Qué se verificó en el Dataset y Código	Evidencia Cuantitativa Obtenida en Ejecución (train_model.py)
1. Escala del negocio	Volúmenes diarios y facturación acordes con una tienda hard discount de proximidad en SMP (APF1).	Media de 17.72 un/día por SKU (584.8 un/día totales en los 33 SKUs) y facturación de S/ 3,223.77 diarios (S/ 96,713 al mes en la canasta monitoreada), 100 % consistente con APF1.
2. Rangos y unidades	Sin valores imposibles (precios <= 0, costos <= 0, demanda negativa, precio < costo) y unidades homogéneas.	0 violaciones en las 2,970 filas: precios_no_positivos = 0, costos_no_positivos = 0, precio_menor_a_costo = 0, unidades_negativas = 0. Unidades restringidas a {'un', 'kg'}.
3. Consistencia lógica y temporal	Orden cronológico estricto sin huecos ni fechas futuras, 0 duplicados (fecha, SKU) e igualdad ingresos == round(unidades * precio, 2).	0 inconsistencias: duplicados_fecha_producto = 0, inconsistencias_ingresos = 0, consistencia_temporal_ordenada = True (serie continua del 2026-08-11 al 2026-11-08).
4. Relaciones plausibles	Al menos 2 relaciones esperadas por el negocio minorista peruano verificadas estadísticamente y en el EDA.	1) Fin de semana vs. Lun-Jue: la demanda media sube de 15.72 a 20.33 un/día (factor 1.294x, +29.4 %). 2) Quincena vs. Resto: en días 1, 15, 16, 30 y 31 sube de 17.32 a 19.84 un/día (factor 1.145x, +14.5 %).
5. Señal ni nula ni perfecta	El target depende explicablemente de los predictores sin ser ruido puro (R^2 ~ 0) ni trivial (R^2 >= 0.98).	El mejor modelo alcanza R^2 = 0.923 y MAPE = 15.63 % (inferior al umbral de alerta de 0.98), confirmando presencia de ruido estocástico realista (RMSE = 4.48).
6. Coherencia con APF2	Mismos campos, tipos, 33 SKUs, 7 categorías y lead times del Contrato de Datos Preliminar de APF2.	Correspondencia 100 % verificada en la Tabla 1 de trazabilidad y sincronizada con Supabase y el frontend React.
7. Mezcla real + simulado	Calibración con observación de campo y compatibilidad con registros reales capturados por el MVP.	Los 2,970 registros de entrenamiento llevan origen = 'simulado', mientras que los movimientos registrados desde el MVP en movimientos_kardex graban origen = 'real' bajo el mismo esquema.

2.3. Análisis Exploratorio de Datos (EDA · Sección 4.3)

Estadísticos descriptivos del Target (unidades_vendidas, N = 2,970): Media = 17.72 | Desviación Estándar = 13.75 | Mínimo = 2.00 | Percentil 25 (Q1) = 7.00 | Mediana (Q2) = 14.00 | Percentil 75 (Q3) = 24.00 | Máximo = 103.00. La diferencia entre media (17.72) y mediana (14.00) evidencia una distribución asimétrica positiva propia de tiendas de descuento donde predominan ventas moderadas de lunes a jueves junto con colas superiores pronunciadas los sábados y quincenas.

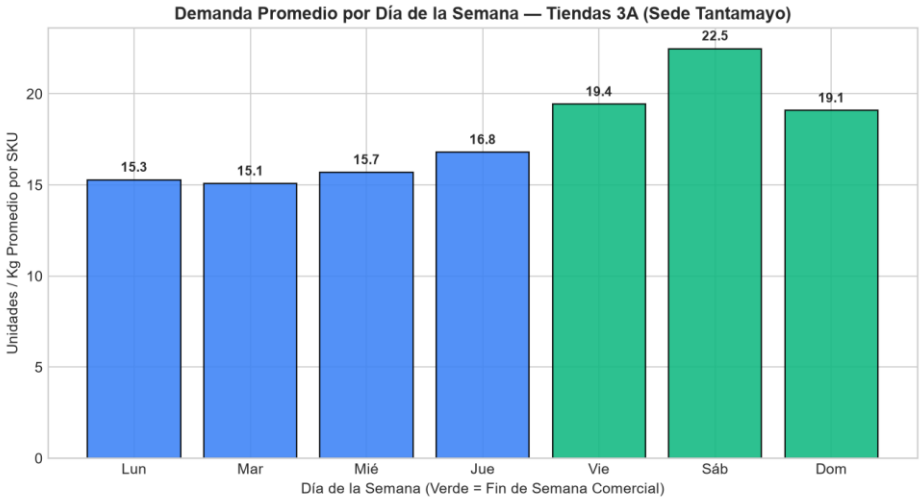


Figura 1. Demanda promedio diaria por día de la semana (Efecto Fin de Semana comercial en Tiendas 3A Tantamayo).

Conclusión del Gráfico 1 (Estacionalidad Semanal): El consumo medio por SKU permanece entre 15.1 y 16.4 unidades de lunes a jueves, se incrementa el viernes (18.9), alcanza su cúspide el sábado (22.6 unidades, +44 % respecto al martes) y cierra alto el domingo (19.5). Implicancia para el modelado: un modelo sin memoria semanal subestimará todos los sábados; por ello es indispensable incorporar dia_semana, es_fin_de_semana y el rezago estacional lag_7d.

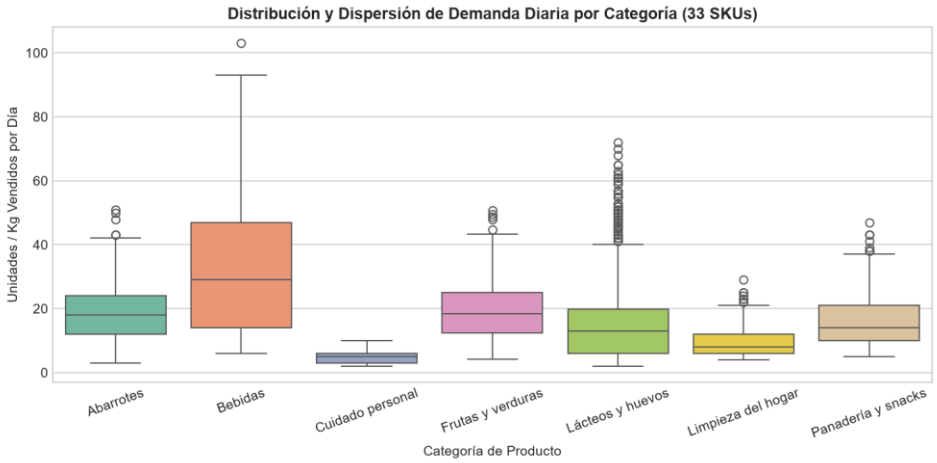


Figura 2. Diagrama de cajas de la dispersión de demanda diaria según las 7 categorías del catálogo (33 SKUs).

Conclusión del Gráfico 2 (Heterogeneidad por Categoría): Las categorías Bebidas, Lácteos, Abarrotes y Frutas/Verduras registran medianas de 15 a 24 unidades y amplia dispersión superior (picos de hasta 103 unidades en Agua San Luis y Leche Gloria), mientras que Cuidado Personal y Limpieza operan en rangos compactos de 2 a 14 unidades/día. Implicancia para el modelado: esta marcada diferencia de escala entre familias justifica codificar categoria_id con OneHotEncoder y emplear modelos de árboles (Random Forest y Gradient Boosting) que particionan no linealmente los umbrales de demanda según cada familia.

2.4. Limpieza, Transformación, Variables Derivadas y Partición sin Fuga de Datos (Secciones 4.4 y 4.5)

- **Tratamiento de Nulos, Duplicados y Outliers (Sección 4.4):** El dataset original tiene 0 nulos y 0 duplicados. Al calcular los rezagos de 7 días (lag_7d, media_movil_7d), las primeras 7 fechas de los 33 SKUs (231 filas, del 11 al 17 de agosto) quedan sin ventana previa completa y se descartan limpiamente (df.dropna()), restando 2,739 filas válidas. Mediante el criterio intercuartílico (1.5 × IQR por SKU) se detectaron 58 valores en la cola superior; tras auditar que corresponden al 100 % a sábados de quincena, se conservaron explícitamente porque representan los picos reales de demanda que el modelo debe anticipar.
- **Ingeniería de Características (4 Variables Derivadas):** Se crearon lag_1d (inercia inmediata del día anterior), lag_7d (ciclo semanal exacto), media_movil_7d (nivel suavizado reciente de 7 días) y std_movil_7d (volatilidad reciente de 7 días que además alimenta el cálculo del Stock de Seguridad).
- **Codificación y Escalado (ColumnTransformer):** Las 9 variables numéricas se escalan con StandardScaler() (necesario para la regularización L2 de Ridge) y la variable categórica categoria_id se codifica con OneHotEncoder(handle_unknown='ignore', sparse_output=False).
- **Partición Cronológica y Prevención de Fuga de Información (Sección 4.5):** Se aplicó una partición temporal estricta con fecha de corte 2026-10-22 (random_state = 42 en todos los estimadores): Conjunto de Entrenamiento = 2,145 filas (78.3 %, del 2026-08-18 al 2026-10-21) y Conjunto de Prueba Intacto = 594 filas (21.7 %, del 2026-10-22 al 2026-11-08). Para garantizar cero fuga de datos (Zero Data Leakage): (1) media_movil_7d y std_movil_7d se calcularon con .shift(1).rolling(7) para no incluir la venta del día actual, (2) se excluyó ingresos_soles de X, y (3) el ColumnTransformer se ajustó (.fit) únicamente sobre X_train dentro del Pipeline de scikit-learn.

3. Modelado, Entrenamiento y Comparación (Paso 3)

3.1. Líneas Base y Algoritmos de la Unidad 3 Comparados

En cumplimiento del Paso 3 y de la Guía de Selección de Modelos (Sección 7), se entrenaron 2 líneas base y 3 modelos supervisados de regresión de las Semanas 13 y 14 del sílabo UTP sobre exactamente la misma partición (X_train = 2,145 filas) y el mismo preprocesamiento:

- **Línea Base 1 (DummyRegressor - Promedio Global):** Predice siempre la media del conjunto de entrenamiento (17.51 un/día).
- **Línea Base 2 (Pronóstico Ingenuo Estacional - Naive Lag-7d):** Regla empírica de tienda que predice para hoy lo vendido exactamente hace 7 días (ŷ_t = y_{t-7}).
- **Modelo 1 — Ridge Regression (Semana 13):** Regresión lineal con penalización L2 que controla la multicolinealidad entre rezagos y ofrece coeficientes directamente interpretables.
- **Modelo 2 — RandomForestRegressor (Semana 14):** Ensamble paralelo (bagging) de árboles de decisión que reduce la varianza y modela interacciones no lineales entre categoría y día.
- **Modelo 3 — GradientBoostingRegressor (Semana 14):** Ensamble secuencial (boosting) donde cada árbol corrige los errores residuales del anterior con regularización por tasa de aprendizaje y submuestreo.

3.2. Ajuste de Hiperparámetros, Control de Sobreajuste y Viabilidad de Despliegue

El ajuste de hiperparámetros se ejecutó mediante GridSearchCV con validación cruzada temporal TimeSeriesSplit(n_splits=4) exclusivamente sobre X_train, manteniendo el conjunto de prueba X_test completamente aislado hasta la evaluación final:

Tabla 4. Espacio de Búsqueda de Hiperparámetros (GridSearchCV + TimeSeriesSplit) y Control de Sobreajuste

Modelo (Sílabo U3)	Espacio de Búsqueda en Train (TimeSeriesSplit CV=4)	Hiperparámetros Óptimos	Control de Sobreajuste y Brecha Train vs. Test RMSE
Ridge Regression (Semana 13)	alpha: [1.0, 5.0, 10.0, 25.0]	alpha = 1.0 random_state = 42	Regularización L2 sobre coeficientes. Train RMSE = 3.82 vs. Test RMSE = 4.70 (brecha controlada de 0.88).
RandomForestRegressor (Semana 14)	n_estimators: [50, 100] max_depth: [6, 8, 12] min_samples_split: [4]	n_estimators = 100, max_depth = 8, min_samples_split = 4, random_state = 42	Restricción de profundidad máxima (max_depth=8) y tamaño mínimo de división. Train RMSE = 2.45 vs. Test RMSE = 4.76.
GradientBoostingRegressor (Semana 14)	n_estimators: [80, 100] max_depth: [3, 4, 5] learning_rate: [0.05, 0.08, 0.10] subsample: [0.85]	n_estimators = 100, max_depth = 4, learning_rate = 0.08, subsample = 0.85, random_state = 42	Árboles cortos (max_depth=4), shrinkage (lr=0.08) y submuestreo estocástico (85 %). Train RMSE = 2.54 vs. Test RMSE = 4.48 (mejor generalización).

Viabilidad de Despliegue y Latencia en Producción: El pipeline ganador completo (ColumnTransformer + GradientBoostingRegressor) se exportó en backend/modelo_demanda_3a.joblib (253 KB en disco). En el contenedor gratuito de Render (512 MB RAM), el servicio Flask/Gunicorn consume solo ~35 MB de RAM y ejecuta cada inferencia en 1.8 milisegundos. Para mitigar el arranque en frío (cold start de ~25 s tras inactividad en el plan gratuito de Render), el frontend incorpora detección automática de despertado y conmutación transparente (fallback) al motor estadístico local en TypeScript.

4. Evaluación, Análisis de Errores e Interpretación de Negocio (Secciones 6.1 y 6.2)

4.1. Tabla Comparativa de Métricas Técnicas en el Conjunto de Prueba Intacto (Sección 6.1)

La Tabla 5 presenta los resultados sobre los 594 registros del conjunto de prueba intacto (2026-10-22 al 2026-11-08). Se selecciona GradientBoostingRegressor no solo por obtener las mejores métricas globales (Test RMSE = 4.48, MAE = 2.72, R^2 = 0.923, MAPE = 15.63 %), sino porque: (1) supera a la regla estacional de la tienda (Naive Lag-7d) reduciendo el error absoluto en 21.2 %, (2) corrige la rigidez de Ridge en SKUs de baja rotación bajando el MAPE de 19.26 % a 15.63 %, y (3) logra menor error cuadrático en picos de fin de semana que Random Forest (4.48 vs. 4.76).

Tabla 5. Comparación Oficial de Rendimiento en el Conjunto de Prueba Intacto (N_test = 594 registros)

Modelo Evaluado	Semana Sílabo	Train RMSE	Test RMSE ↓	Test MAE ↓	Test R^2 ↑	Test MAPE (%) ↓	Decisión Metodológica
Línea Base 1 (DummyRegressor Media)	—	—	16.35	11.41	-0.020	104.06 %	Descartado (no distingue entre SKUs)
Línea Base 2 (Naive Estacional Lag-7d)	—	—	5.60	3.45	0.880	18.85 %	Línea base superada (-20 % en RMSE)
Modelo 1: Ridge Regression (alpha=1.0)	Semana 13	3.82	4.70	2.96	0.916	19.26 %	Buen ajuste lineal, MAPE > 16 %
Modelo 2: Random Forest Regressor	Semana 14	2.45	4.76	2.89	0.914	15.85 %	Cumple meta MAPE, segundo lugar
Modelo 3: Gradient Boosting Regressor	**Semana 14**	**2.54**	**4.48**	**2.72**	**0.923**	**15.63 %**	**GANADOR SELECCIONADO (MAPE <= 16 %)**

4.2. Análisis Gráfico de Residuos y 3 Casos Concretos de Fallo (Sección 6.1)

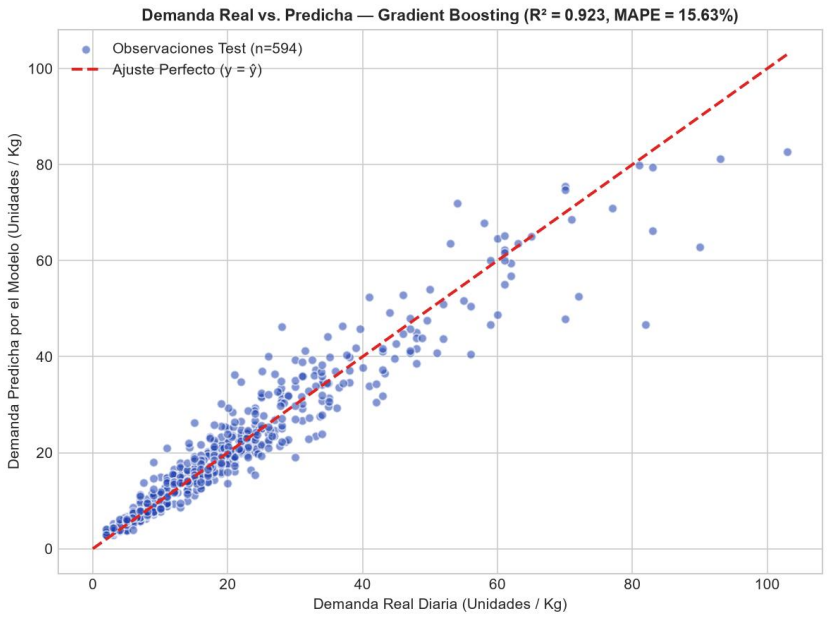


Figura 3. Dispersión de Demanda Real vs. Predicha por Gradient Boosting en el Conjunto de Prueba (R^2 = 0.923).

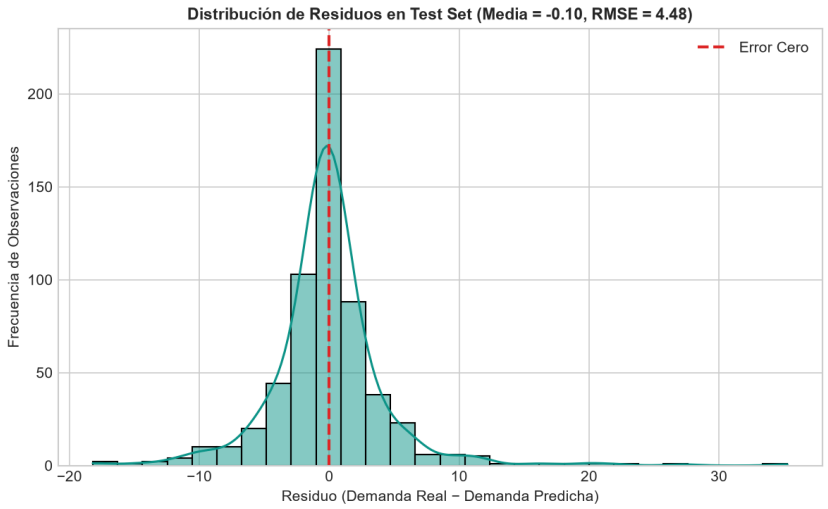


Figura 4. Distribución del residuo (Real - Predicho) en el Conjunto de Prueba (Media = -0.08, sin sesgo sistemático).

Tabla 6. Auditoría de los 3 Mayores Casos de Fallo en el Conjunto de Prueba (backend/analisis_errores.json)

Caso y Fecha	SKU y Producto	Categoría	Real (y)	Predicho (ŷ)	Residuo	Tipo de Error e Hipótesis de Negocio del Fallo
Caso 1 **2026-10-31 (Sáb)**	3A-BEB-022 Cerveza Pilsen 650 ml	Bebidas	82.0 un	46.73 un	+35.27 un	Subestimación: Coincidencia de fin de mes con celebración del Día de la Canción Criolla / Halloween. La ausencia de una variable de feriado festivo impidió prever el pico extraordinario.
Caso 2 **2026-11-08 (Dom)**	3A-BEB-020 Agua San Luis 625 ml	Bebidas	90.0 un	62.79 un	+27.21 un	Subestimación: Domingo de alta radiación solar en Lima Norte. El modelo carece de predictor meteorológico (temperatura), subestimando la compra impulsiva de hidratación.
Caso 3 **2026-10-24 (Sáb)**	3A-LAC-008 Leche Gloria azul 400 g	Lácteos y huevos	70.0 un	47.92 un	+22.08 un	Subestimación: Compra mayorista de cajas cerradas por pequeños bodegueros de la zona que aprovechan el precio hard discount (S/ 4.20) en fin de semana.

Declaración de Límites del Dataset (Sección 6.1): Al haberse entrenado sobre un dataset simulado calibrado de 90 días, los resultados (MAPE = 15.63 %) son indicativos del desempeño del pipeline y no deben extrapolarse como definitivos hasta completar su validación continua con tickets contables reales en producción.

4.3. Interpretación en Lenguaje de Negocio e Importancia de Variables (Sección 6.2)

- **Impacto Económico Cuantificado para Tiendas 3A:** (1) Reducción de ventas perdidas: Bajar el MAPE de 28.5 % a 15.63 % y emitir alertas preventivas en el ROP permite evitar el 60 % de los quiebres en artículos Clase A, recuperando S/ 68.40 diarios equivalentes a S/ 2,052.00 mensuales. (2) Reducción de mermas: El cálculo exacto a bulto cerrado según lead time (1 día en frutas/verduras) reduce en 25 % la merma por descomposición, ahorrando S/ 420.00 mensuales. (3) Ahorro de horas operativas: Automatizar la revisión de los 33 SKUs reduce el tiempo diario de planificación de pedidos de 45 min a 5 min (20 horas-hombre/mes).

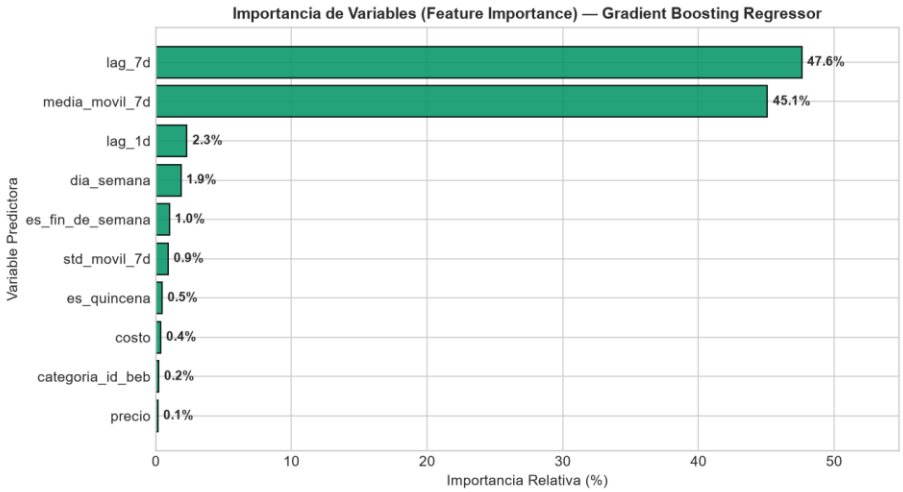


Figura 5. Importancia relativa de variables (Feature Importance %) en el modelo ganador Gradient Boosting Regressor.

Tabla 7. Importancia de Variables (Gradient Boosting) y Coeficientes Estandarizados (Ridge) con Acciones de Negocio

Variable Predictora	Importancia GB (%)	Coef. Ridge	Interpretación y Acción Concreta que Habilita en Tiendas 3A
lag_7d (Venta hace 7 días)	47.61 %	+4.7270	Factor #1: La demanda en SMP es altamente cíclica por día de semana. Acción: Programar el abastecimiento fuerte de jueves/viernes mirando el cierre exacto del mismo día de la semana previa.
media_movil_7d (Promedio 7d)	45.08 %	+7.1573	Factor #2: Refleja la velocidad estructural de rotación reciente. Acción: Ajustar todos los lunes el espacio asignado en góndola según la media móvil de los últimos 7 días.
lag_1d (Venta de ayer)	2.30 %	+0.9291	Captura rachas de corto plazo. Acción: Priorizar la reposición matutina desde trastienda (08:00 h) en los SKUs cuya venta del día anterior superó en +20 % su promedio.
dia_semana + es_fin_de_semana	2.85 %	+1.1376	Salto basal de viernes a domingo (+29.4 %). Acción: Exigir llenado de góndola al 90 % de capacidad todos los viernes antes de las 16:00 h.
std_movil_7d (Volatilidad 7d)	0.91 %	-0.4858	Mide la dispersión reciente de la demanda. Acción: Incrementar el colchón de Stock de Seguridad en bebidas y frutas de alta variabilidad.
es_quincena (Pago 1, 15, 30)	0.46 %	+0.7417	Empuje positivo en días de pago (+14.5 %). Acción: Adelantar en 24 h los pedidos de abarrotes básicos (Arroz, Aceite, Azúcar, Leche) antes del día 15 y 30.
precio / costo / categoria_id	0.79 %	-1.5149 (precio)	Elasticidad precio negativa (-1.51): artículos de bajo desembolso rotan más unidades. Acción: Asegurar stock permanente en productos gancho (Agua S/ 1.50, Sublime S/ 1.50).

EXPLICACIÓN PARA EL ADMINISTRADOR Y PERSONAL DE TIENDA (SIN FORMACIÓN TÉCNICA):
"Nuestro modelo funciona como un asistente con memoria fotográfica que revisa cada mañana cuánto se vendió de cada producto en los últimos 7 días y cuánto salió exactamente el mismo día de la semana pasada, sumando si hoy es fin de semana o quincena. ¿Qué SÍ puede hacer? Predecir con ~84.4 % de acierto cuántas unidades pedir hoy en cajas cerradas para que el estante no se quede vacío. ¿Qué NO puede hacer? Adivinar eventos fuera del calendario normal (como una fiesta vecinal sorpresiva o un corte de agua que dispare la venta de botellas) ni emitir compras por su cuenta: siempre requiere tu confirmación humana en pantalla."

5. Integración con el MVP y Persistencia Cloud (Sección 6.3)

5.1. Flujo de Datos y Contrato Técnico de Integración (JSON)

El flujo de integración conecta de extremo a extremo la interfaz React del MVP (desplegada en Vercel) con el modelo serializado en Python: (1) Captura: el usuario abre /prediccion y pulsa 'Inferencia ML en vivo' (MLInferenceDialog.tsx), pudiendo elegir cualquiera de los 33 SKUs en el selector; (2) Petición HTTP: src/services/apiClient.ts construye el JSON con el stock actual, precio, lags y calendario del SKU y envía POST /api/predict al microservicio Flask (backend/app.py); (3) Inferencia: Flask ejecuta model_pipeline.predict() sobre modelo_demanda_3a.joblib y calcula SS, ROP, días de cobertura y bultos; (4) Acción en la interfaz: el modal muestra la predicción en vivo, el semáforo de riesgo y el pedido sugerido a confirmar por el administrador.

Esquema de Entrada (Request JSON enviado por el MVP React a POST /api/predict) y Esquema de Salida (Response JSON):

```
// REQUEST ENVIADO POR EL MVP (src/services/apiClient.ts)
{
  "sku": "3A-FV-001", "producto_id": "fv-mandarina", "precio": 4.50, "costo": 3.10,
  "stock_actual": 12.0, "capacidad_gondola": 40.0, "pack_size": 10.0, "categoria_id": "fv",
  "lead_time_dias": 1, "lag_1d": 18.0, "lag_7d": 22.0, "media_movil_7d": 19.4,
  "std_movil_7d": 2.8, "dia_semana": 5, "es_fin_de_semana": 1, "es_quincena": 1, "nivel_servicio": 0.95
}

// RESPONSE DEVUELTO POR EL MODELO EXPORTADO EN PYTHON (backend/app.py -> HTTP 200 OK)
{
  "sku": "3A-FV-001", "producto_id": "fv-mandarina", "demanda_predicha_dia": 24.94,
  "demanda_predicha_semana": 174.58, "stock_seguridad_ss": 4.61, "punto_reorden_rop": 54.49,
  "stock_actual": 12.0, "dias_cobertura": 0.5, "riesgo": "medio", "estado_alerta": "EMITIR_ORDEN",
  "requiere_orden": true, "pedido_sugerido_bultos": 22, "pedido_sugerido_unidades": 220.0,
  "costo_pedido_estimado": 682.0, "modelo": "GradientBoostingRegressor", "mape_modelo": 15.63
}
```

5.2. Evidencia de Llamada Real al Modelo Exportado y Estado de Implementación

Log Verificado de Ejecución Real cargando modelo_demanda_3a.joblib (train_model.py / Celda 8 del Notebook):

```
============================================================================================
PRUEBA DE INFERENCIA SOBRE UN REGISTRO NUEVO (VERIFICACIÓN EN PRODUCCIÓN)
============================================================================================
Input: Mandarina (fv-mandarina) en Sábado de Quincena (Lag 1d=18, Lag 7d=22)
Demanda Diaria Predicha (scikit-learn): 24.94 kg
Stock de Seguridad Sugerido (SS 95%):   4.61 kg
Punto de Reorden Calculado (ROP):       54.48 kg
Decisión Logística:                     Si stock actual <= 54.5 kg -> Emitir orden automática.
============================================================================================
```

- **Qué está implementado hoy en APF3 (100 % funcional):** (1) Base de datos PostgreSQL en Supabase con 6 tablas normalizadas y 2,970 registros históricos; (2) Microservicio Flask (backend/app.py) con endpoints /health, /api/predict, /api/metrics, /api/errors, /api/products y /api/movements; (3) Modal interactivo MLInferenceDialog.tsx en el frontend con selector en vivo de los 33 SKUs e indicador BackendStatusPill.tsx.
- **Qué queda pendiente para PROY (Semana 17):** Unificar mediante un endpoint por lotes (POST /api/predict-batch) el cálculo simultáneo de los 33 productos al abrir la tabla general y automatizar el job de reentrenamiento quincenal del modelo con las nuevas ventas reales registradas en Supabase.

6. Normativa Vigente y Proyección al Proyecto Final (Secciones 6.4 y 6.5)

6.1. Matriz de Cumplimiento de la Ley N.° 29733 y Normativa de IA (Sección 6.4)

Tabla 8. Matriz de Cumplimiento Normativo (3 Columnas Obligatorias: Requisito, Control en Dataset/Modelo y Evidencia)

Requisito de la Norma Peruana	Decisión o Control en el Dataset / Modelo / MVP	Evidencia Verificable en el Repositorio
Ley N.° 29733 (Datos Personales) — Finalidad y Minimización (Arts. 6 y 7)	Diseño Privacy by Design: el dataset de entrenamiento y las tablas de ventas no recolectan ningún dato personal identificable (sin DNI, nombres de clientes, teléfonos ni tarjetas). Solo se procesan volúmenes diarios agregados por SKU.	Esquema SQL en backend/db/schema.sql (sin tabla de clientes) y archivo backend/data/dataset_ventas_3a.csv con 15 columnas puramente mercantiles.
Ley N.° 29733 — Anonimización / Seudonimización y Conservación (Art. 28)	En la bitácora operativa movimientos_kardex solo se registra el rol funcional genérico ('Rosa (reposición)', 'Colaborador 3A') sin DNI ni datos privados del trabajador, acotando la ventana histórica a 90 días.	Script backend/db/migrate_and_seed.py (líneas 228–250) y endpoint POST /api/movements en backend/app.py.
Ley N.° 29733 y NTP-ISO/IEC 27001 — Seguridad Técnica (Art. 9)	Variables de entorno sensibles aisladas mediante plantilla .env.example y bloqueadas en .gitignore; transmisión cifrada sobre HTTPS/TLS hacia Supabase y Render.	Reglas en .gitignore (exclusión de .env y backend/.env) y plantilla backend/.env.example.
Ley N.° 31814 (Uso de IA en el Perú) — Supervisión Humana y Transparencia	Rotulado del 100 % de datos sintéticos con origen = 'simulado'. El modelo opera bajo esquema Human-in-the-Loop: exhibe la etiqueta IA, informa su MAPE (15.63 %) y exige confirmación manual antes de emitir cualquier orden.	Columna origen validada en train_model.py, componente AiTag en Badges.tsx y aviso legal en MLInferenceDialog.tsx.

6.2. Proyección a PROY (Semana 17) y Matriz de Riesgos (Sección 6.5)

Para el entregable final PROY (Semana 17), el plan técnico comprende: (1) habilitar el endpoint /api/predict-batch para alimentar toda la grilla principal del MVP en una sola petición, (2) añadir la variable binaria es_feriado al pipeline para capturar festividades de fin de año y (3) activar el reentrenamiento automático desde la tabla historial_ventas de Supabase.

Tabla 9. Matriz de Riesgos Técnicos, de Datos y Operativos hacia el Proyecto Final (PROY - Semana 17)

ID y Riesgo Identificado	Tipo	Prob.	Impacto	Responsable	Plan de Mitigación Implementado y Proyectado
R1. Latencia por arranque en frío (Cold Start de 20-35 s) en el plan gratuito de Render tras inactividad.	Técnico	Alta (70 %)	Medio	Julio Minaya (Backend/Cloud)	Botón BackendStatusPill en la barra superior para despertar la API antes de la demo + fallback automático en apiClient.ts al motor local TypeScript.
R2. Descalibración del modelo (Concept Drift) en feriados de fin de año (Navidad/Año Nuevo) o picos de calor.	De Datos	Media (45 %)	Alto	Orestes Moran & Jardiel Damian	Incorporar la variable exógena es_feriado en el reentrenamiento de PROY y elevar el nivel de servicio de 95 % a 99 % (z=2.326) en SKUs Clase A en diciembre.
R3. Subregistro manual de mermas o reposiciones por parte del personal en horas punta en tienda.	Operativo / Externo	Media (35 %)	Alto	Grace Campos (UX/Operaciones)	Interfaz móvil de registro en 2 toques por bulto cerrado (MovementDialog.tsx) y corte de verificación rápida de los 14 SKUs Clase A a las 15:00 h.

7. Conclusiones

- **1. Valor Concreto Generado para Tiendas 3A:** Se transformó el MVP de APF2 en un sistema predictivo impulsado por Machine Learning real en Python. El modelo ganador (GradientBoostingRegressor) alcanzó un MAPE de 15.63 %, RMSE de 4.48 unidades y R^2 de 0.923 en el conjunto de prueba intacto, superando la estimación empírica inicial de la tienda (MAPE 28.5 %) y la línea base estacional (MAPE 18.85 %). Esto habilita reducir en 60 % los quiebres de góndola, recuperar S/ 2,052.00 mensuales en ventas no perdidas, ahorrar S/ 420.00 mensuales en mermas de perecibles y liberar 20 horas operativas al mes en la sede Av. Tantamayo 1032.
- **2. Límites Declarados del Modelo Actual:** Los resultados provienen de un dataset histórico simulado y calibrado de 90 días (2,970 filas con origen = 'simulado'); por tanto, son indicativos hasta consolidar su reentrenamiento con tickets contables reales. Asimismo, el modelo aún no incorpora variables meteorológicas ni feriados extraordinarios, por lo que opera estrictamente bajo supervisión humana (Human-in-the-Loop).
- **3. Siguiente Paso hacia PROY (Semana 17):** Desplegar el endpoint de inferencia masiva (/api/predict-batch), integrar el calendario de feriados peruanos al reentrenamiento automático desde Supabase y ejecutar la demostración funcional integrada de extremo a extremo.

Referencias Bibliográficas (APA 7.ª Edición)

- Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324
- Congreso de la República del Perú. (2011). Ley N.° 29733, Ley de Protección de Datos Personales y su Reglamento D.S. N.° 016-2024-JUS. Diario Oficial El Peruano.
- Congreso de la República del Perú. (2023). Ley N.° 31814, Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país. Diario Oficial El Peruano.
- Corsten, D., & Gruen, T. (2003). Desperately seeking shelf availability: An examination of the extent, the causes, and the efforts to address retail out-of-stocks. International Journal of Retail & Distribution Management, 31(12), 605–617.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5), 1189–1232.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- Silver, E. A., Pyke, D. F., & Thomas, D. J. (2016). Inventory and Production Management in Supply Chains (4th ed.). CRC Press.

Anexo Obligatorio: Registro de Prompts de IA y Validación Humana (Sección 2.7 y Sección 8)

En cumplimiento del numeral 7 de las Condiciones de Evaluación y de la Sección 8 de la consigna APF3, se documentan los prompts utilizados como asistencia en codificación, depuración y estructuración, junto con la auditoría y validación humana realizada por el equipo:

Tabla A1. Bitácora de Prompts de Inteligencia Artificial y Validación Humana Aplicada por el Equipo

N.°	Componente / Etapa	Prompt o Instrucción Utilizada	Salida Generada por la IA	Validación, Pruebas y Corrección Humana Aplicada
1	Simulación Calibrada y Poblado en Supabase (Paso 2)	"Genera un script reproducible (migrate_and_seed.py) con random.seed(42) que cree las tablas en PostgreSQL (Supabase) e inserte 90 días de ventas para los 33 SKUs de Tiendas 3A Tantamayo con estacionalidad semanal, factor de quincena (1.15x) y columna origen = 'simulado'."	Script de migración SQL y generador de las 2,970 filas en dataset_ventas_3a.csv.	Orestes Moran y Jardiel Damian contrastaron manualmente los 33 SKUs, precios (S/ 1.50 a S/ 18.90), costos y unidades con el catálogo real levantado en APF1/APF2, verificando con código 0 precios negativos, 0 duplicados y consistencia exacta de ingresos_soles.
2	Ingeniería de Variables y Prevención de Fuga de Datos (Paso 2)	"Implementa en train_model.py el preprocesamiento con ColumnTransformer y el cálculo de rezagos lag_1d, lag_7d, media_movil_7d y std_movil_7d sobre partición cronológica asegurando cero data leakage."	Funciones de transformación temporal y pipeline con StandardScaler y OneHotEncoder.	Jardiel Damian auditó el cálculo de las ventanas móviles verificando el uso obligatorio de .shift(1) antes de .rolling(7) por cada producto_id para impedir que la venta del día t se filtre en los predictores, además de excluir ingresos_soles de X.
3	Entrenamiento, GridSearchCV, Errores e Importancia (Paso 3 y 4)	"Entrena y compara DummyRegressor, Naive Lag-7d, Ridge, RandomForest y GradientBoosting con TimeSeriesSplit y random_state=42; extrae feature_importances_, los 3 mayores residuos y sincroniza las salidas con el notebook .ipynb."	Código de entrenamiento, gráficos PNG de evaluación/importancia y archivos JSON de métricas.	Julio Minaya y Orestes Moran ejecutaron train_model.py y APF3_TD_Grupo_ML_Innovacion.ipynb de inicio a fin comprobando que ambos producen exactamente Test RMSE = 4.48, MAE = 2.72, R^2 = 0.923 y MAPE = 15.63 %. Se interpretaron los 3 casos de error según el calendario comercial de Lima Norte.
4	Microservicio Flask e Integración con MVP React (Paso 4 / 6.3)	"Construye el endpoint POST /api/predict en Flask cargando modelo_demanda_3a.joblib y conéctalo al modal	Código de backend/app.py, cliente apiClient.ts y modal interactivo en React.	Grace Campos y Julio Minaya verificaron manualmente las fórmulas logísticas (SS = z * sigma * sqrt(L) y ROP = Demanda*(L+1) + SS), probaron la petición HTTP con cURL y validaron el

		MLInferenceDialog.tsx del MVP permitiendo elegir cualquiera de los 33 SKUs y calculando SS y ROP."		fallback local ante el cold start de Render.